

텍스트마이닝 개인 과제 보고서

주제: 토픽 모델링을 통한 축구 부상 유형 및 위험 요인 탐색

2021603038 송호성

1. 서론

- 주제 소개

최근 프로 축구 대회의 경기수가 증가함에 따라 선수들의 부상 빈도가 잦아지고 있다. 이에 따라 본 프로젝트에서는, 토픽 모델링을 통해 축구 선수의 부상 유형과 부상 요인에 관한 주요 토픽을 도출하여 향후 부상 예방 전략 수립에 도움을 주고자 한다.

2. 데이터 수집 및 전처리

- 데이터 수집 과정

Web of Science를 활용하여 축구 선수의 부상 관련 문헌을 수집하였다. 검색 조건은 TS 필터를 이용하여 다음과 같이 설정하였다. (TS = (soccer OR “association football”) AND TS = (“injury risk” OR “injury type”) NOT TS = (“American football” OR rugby)).

검색 결과, 총 1,211편의 문헌이 수집되었으며, 이 중에서 초록(Abstract) 정보가 포함된 1,194편의 문헌을 선별하였다. 이후 중복 문헌 제거 및 전처리 과정을 거쳐 최종적으로 1,124개의 유효한 초록 텍스트를 토픽 모델링 분석에 활용하였다.

- 전처리 과정 및 결과

본 프로젝트에서는 두 가지 주요 토픽 모델링 기법인 LDA와 BERTopic을 순차적으로 적용하였다. 이는 각 기법의 특성과 한계를 고려하여 보다 입체적인 분석을 수행하고자 하는 목적에서 비롯되었고, 이에 따라 전처리 과정도 아래와 같이 2가지로 분류된다.

- [표 1] LDA 활용을 위한 전처리 과정

전처리 과정	결과
소문자 변환	텍스트의 모든 문자를 소문자로 통일 -> 동일한 의미의 단어 정제
특수문자 정제	정규표현식 사용 -> 불필요한 기호성 잡음 제거
불용어 제거	[NLTK 불용어 리스트 + 토픽 분리에 기여하지 않는 단어 커스터마이징] 제거
토큰화	RegexTokenizer 활용 -> 각 문장을 단어 단위로 분리
표제어 추출	spaCy의 자연어 처리 모델을 활용 -> 각 단어를 표제어 형태로 정규화
BoW 및 TF-IDF	단어의 빈도에 가중치 조정 -> 문서 내 중요 단어가 더욱 잘 반영됨

- [표 2] BERTopic 활용을 위한 전처리 과정

전처리 과정	결과
소문자 변환	텍스트의 모든 문자를 소문자로 통일 -> 동일한 의미의 단어 정제
특수문자 정제	LDA와 달리 수치 기반 표현 유지(소수점, %) -> 문맥적 의미의 일부로 반영
불용어 제거	[NLTK 불용어 리스트 + 의미 분별력이 낮은 단어 커스터마이징] 제거
토큰화, 표제어 추출	문장 단위의 의미를 임베딩 하기 때문에 해당 과정 생략
문장 임베딩	SentenceTransformer의 “all-MiniLM-L6-v2” 모델을 사용하여 각 문장을 고차원 의미 벡터로 변환
차원 축소 및 클러스터링	UMAP -> 벡터 차원 축소 / HDBSCAN -> 유사한 문장 간의 밀도 기반 군집화 토픽별 대표 단어는 CountVectorizer와 ClassTFIDFTransformer를 통해 추출되며, 이는 해석이 쉬운 키워드 기반 주제 요약으로 이어짐

3. 토픽 모델링 결과

- 토픽 모델링 적용 기법

LDA와 BERTopic은 각각 통계 기반의 전체 주제 파악, 의미 기반 임베딩을 통한 미세 주제 분석에 강점을 지닌다. 본 프로젝트에서는 이들의 상호보완적 특성을 활용하여 보다 입체적인 분석을 수행하고자 두 기법을 병행하였다.

- 토픽 도출 결과

- [표 3] LDA 분석 결과

토픽 번호	주요 키워드	해석
Topic 1	injury, incidence, review, study, sport, turf, grass, risk	스포츠에서 발생하는 부상의 발생률 및 관련 환경 요인(잔디, 인조잔디)에 대한 고찰
Topic 2	knee, jump, abduction, landing, hip, angle, flexion, biomechanic	무릎 관절 중심의 부상 메커니즘과 착지 동작, 관절 가동범위 등의 생체역학적 분석 주제
Topic 3	load, workload, training, rpe, session, sleep, intensity, sprint	운동 부하 및 훈련 강도 관리, 피로도 및 회복 등 선수의 컨디션에 따른 부상 위험 관계 분석
Topic 4	hamstring, muscle, quadriceps, torque, eccentric, isokinetic, emg, imbalance	햄스트링과 대퇴근 중심의 근육 기능 및 비대칭성, 근력 평가 등을 다룬 근골격계 부상 유형 중심 주제

- [표 4] BERTopic 분석 결과

토픽 번호	주요 키워드	해석
Topic 0	ligament, knee, hamstrings	무릎 및 인대 부상
Topic 1	injuries, ankle, athletes	일반적인 운동 손상 및 신체 부위
Topic 2	training, exertion, workload	훈련 강도 및 부하 관련 위험 요인
Topic 3	concussion, headgear, head	뇌진탕 및 두부 손상

Topic 4	stressors, anxiety, psychological	심리적 스트레스 및 정신적 요인
Topic 5	turf, grass, footballers	운동장 표면 관련 요인
Topic 6	fitness, svm, predicting	예측 모델링과 선수 상태 평가
Topic 7	training, maturity, assessment	신체 성장, 트레이닝 평가
Topic 8	footwear, traction, insoles	신발 착용 및 발바닥 마찰 요인

- 분석 결과 요약

두 기법 모두 주제(축구 부상 유형 및 위험 요인)에 부합하는 결과를 도출하였다. LDA는 명확한 주제 경계를 통해 전체적인 흐름을 파악하는 데 적절한 도구로 작용하였고, BERTopic은 뇌진탕, 심리적 요인, 신발 착용 환경 등의 비정형적 위험 요인까지 포착해내며 분석의 깊이를 더했다.

한편, 본 보고서에는 시각화 자료를 포함하지 않았으며, lda_analysis.py와 bertopic_analysis.py를 실행하면 각 분석 결과에 대한 시각화 자료(.html) 및 .csv 파일이 자동으로 생성되도록 구성하였다. LDA는 pyLDAvis를 통해 주제별 키워드 시각화를 지원하고, BERTopic은 다양한 시각화 함수와 문서-토픽 정보를 저장하는 기능을 지원한다.

4. 생성형 AI 적용 및 비교 결과

- ChatGPT 기반 주요 토픽 도출

ChatGPT에게 “축구 선수에게 흔히 발생하는 부상 유형과 부상 요인에 관한 토픽 도출”을 요청한 결과, 대표적인 부상 유형으로는 햄스트링 파열, ACL 손상, 발목 염좌, 허리 및 척추 부상이 언급되었다. 또한, 부상의 요인으로는 피로, 근육 불균형, 훈련량, 구장 상태 등이 제시되었다.

- 토픽 모델링 및 ChatGPT 기반 주요 토픽 도출 결과 비교

LDA는 단어의 출현 빈도를 기반으로 전체적인 주제를 도출하는 데 적합하지만, 개념의 다양성은 제한적이었다. 반면 BERTopic은 의미 기반 임베딩을 통해 LDA로는 분리되기 어려운 주제를 정교하게 클러스터링하고, 정성적 요인까지 효과적으로 포착해냈다.

이를 ChatGPT의 토픽과 비교한 결과, LDA는 부상 유형과, BERTopic은 부상 요인과 높은 유사성을 보였다. 결과적으로 두 모델을 병행함으로써 공통된 핵심 주제는 물론, 구체성과 확장성 측면에서도 ChatGPT 기반 분석의 해석적 깊이와 신뢰성을 한층 강화할 수 있었다.

5. 결론

이번 프로젝트에서 축구 부상 관련 문헌을 LDA와 BERTopic을 활용해 토픽 모델링함으로써, 반복적으로 등장하는 부상 유형 및 요인에 대해 파악할 수 있었다. 두 모델은 서로 다른 방식으로 주제를 분해하면서도 공통적인 통찰을 제공하였고, 이를 통해 보다 심층적인 부상 위험 요인 이해가 가능했다. 이는 향후 부상 위험 관리 및 훈련 시스템 설계 등 선수 보호를 위한 기초 자료로 활용될 수 있을 것이다.